

國立臺北商業大學

資訊管理系 人工智慧科技應用學士後專班

115 AI 資訊專題研究報告



組別：第 P11303 組

題目：“iMercury”——整合人工智慧應用之電子郵件自動
管理系統

第一指導老師：蒯思齊 老師

第二指導老師：蔡文隆 老師

組長：P1136104 余明憲

組員：P1136105 吳彥瑾 P1136110 吳奕萱

P1136122 張育馨 P1136129 葉佳穎

中 華 民 國 1 1 5 年 6 月 16 日

國立臺北商業大學專題課程作品

電子文件上網授權書

本授權書所授權之作品為授權人在 國立臺北商業大學 資訊管理(科/系)

 組/專班 學年度 第 學期專題課程之成果報告作品。

專題題目：

指導教授：

☐ 本人 ☐ 團體著作人

☐ 同意 提供讀者基於個人非營利性質之線上檢索、閱覽、下載或列印。

茲同意將授權人擁有著作權之上列論文全文(含摘要)無償授權本人就讀學校(國立臺北商業大學)圖書館,不限地域、時間與次數,以微縮、光碟或其他各種數位化方式將上列作品收錄、重製與利用,並得將數位化之上列作品及其電子檔上載資料庫系統。於著作權法合理使用範圍內,讀者得進行線上檢索、閱覽、下載或列印。

專題課程成果報告作品全文上載網路公開之範圍及時間：

本校區域網路 ☐ 立即公開

☐ 自中華民國 年 月 日公開

校外網際網路 ☐ 立即公開

☐ 自中華民國 年 月 日公開

☐ 不同意 提供讀者基於個人非營利性質之線上檢索、閱覽、下載或列印。

若特殊因素需延後公開,請另填寫專題研究報告延後公開申請書

授權人

簽 名

(作品若為團體作品,請每一位團體成員均應簽署)

中 華 民 國 年 月 日

“iMercury” — 整合人工智慧應用之電子郵件自動管理系統

"iMercury": An AI-Integrated Automated Email Management System

摘要

本研究開發「iMercury」整合人工智慧應用之電子郵件自動管理系統，旨在解決企業內部行政依賴人力判讀郵件導致的低效率問題。系統核心整合自然語言處理（NLP）意圖分析、SAM 影像分割模型及大語言模型（LLM），並透過 n8n 流程自動化引擎與 LINE Bot 實現全自動轉寄與即時通知。在實際運作上，系統先利用正規表示式萃取郵件特徵，並建立部門知識庫，隨後導入 LLM 並配合少量樣本提示與本體論約束機制，確保分類精準並消除幻覺；針對圖片附檔則由 BLIP 模型進行描述分析。經測試驗證，本系統預計可提升處理效率達 80% 以上並降低 70% 誤判率，在優化營運數據之餘，更實踐了 ESG 永續治理目標，具備轉化為完整企業行政自動化平台之潛力。

關鍵詞：AI agent、流程自動化、自然語言處理

Abstract

This study develops iMercury, an AI-driven email management system designed to automate manual administrative workflows and enhance processing efficiency. The architecture integrates Natural Language Processing (NLP) for intent analysis, the Segment Anything Model (SAM) and BLIP for image recognition, and Large Language Models (LLM) for precise classification and summarization. By utilizing the n8n workflow automation engine and LINE Bot, the system achieves a fully automated pipeline—from initial reception to standardized forwarding.

To ensure high accuracy and stability, the system employs few-shot prompting and ontology constraints within a knowledge base to minimize model hallucinations. Experimental results demonstrate that iMercury can improve operational efficiency by over 80% and reduce misclassification rates by 70%. Beyond streamlining data management, the system aligns with ESG sustainability goals and digital transformation strategies, offering a scalable and secure solution for intelligent corporate governance and administrative automation.

Keyword : AI agent, workflow automation, Natural Language Processing

目錄

第 1 章 緒論	1
1.1 研究背景與動機	1
1.2 研究問題與挑戰	1
1.3 研究目的	1
1.4 預期貢獻	1
第 2 章 產業現況與需求分析	3
2.1 產業背景與現況	3
2.2 痛點與需求分析	3
2.3 數位轉型與 ESG 驅動之需求	3
2.4 現有電子郵件自動管理系統與本研究之比較	4
第 3 章 研究方法與系統架構	8
3.1 研究方法	8
3.2 系統架構: n8n 流程自動化	9
3.3 系統架構: 文字處理--電子郵件文字特徵提取與部門分類模型	10
3.3.1 資料處理與分類架構萃取&AI 標記引擎與交叉驗證	10
3.3.2 資料分布調整與採樣策略&深度學習分類器建構	11
3.4 系統架構: 影像處理	13
3.4.1 系統總體架構設計與數據流	13
3.4.2 基於 ITM 的瑕疵檢測詳細流程	14
3.4.2.1 特徵空間映射 (Feature Extraction & Embedding)	14
3.4.2.2 跨模態匹配評分 (Image-Text Matching Scoring)	15
3.4.2.3 基於動態閾值之決策邊界(Thresholding & Score Comparison)	16
第 4 章 研究結果	17
4.1 系統實作成果	17

4.2 文字分類模組效能評估.....	20
4.2.1 類別平衡對模型準確率之影響與量化指標	20
4.2.2 Bi-LSTM 與 CNN 模型表現對比.....	21
4.2.3 錯誤分析與混淆矩陣探討.....	22
4.3 影像分析模組—BLIP 與 Ollama 影像處理實驗之執行成果.....	23
4.3.1 Image Captioning 與 Ollama 實驗執行成果	24
4.3.2 Visual Question Answering 與 Ollama 實驗執行成果	24
4.3.3 Feature Extraction 實驗執行成果	25
4.3.4 Image-Text Matching 實驗執行成果	25
4.3.5 影像分析模組實驗執行成果與後續補強方向	26
第 5 章 結論.....	28
5.1 研究結論	28
5.2 研究貢獻總結	29
5.3 研究限制	30
5.4 未來研究方向	30
參考文獻.....	32
附錄：.....	35
1. 專案時程與組織分工.....	35
2. 評審意見回覆.....	35
3. 其他相關資料.....	38

圖目錄

▲ 圖 3-1：本系統核心架構	8
▲ 圖 3-2：n8n 流程自動化	9
▲ 圖 3-3：基於大語言模型輔助與深度學習之郵件分類系統架構圖	10
▲ 圖 3-4：多重專家共識標記後之原始樣本數分佈圖	12
▲ 圖 3-5：實施階梯式採樣平衡後之訓練集樣本分佈圖	12
▲ 圖 3-6：系統整體架構及影像處理數據流	13
▲ 圖 3-7：基於 IIM 的瑕疵檢測詳細流程圖	14
▲ 圖 4-1：系統收到新電子郵件立即觸發機制	17
▲ 圖 4-2：系統自動建立轉寄郵件並發送至對應部門信箱	19
▲ 圖 4-3：本研究加入 LINE Bot 即時通訊提醒功能	19
▲ 圖 4-4：Bi-LSIM 與 CNN 於各部門之 F1-score 表現對照圖	22
▲ 圖 4-5：最終版 Bi-LSIM 模型之混淆矩陣熱力圖	22
▲ 圖 4-6：實驗測試圖片-破損手機螢幕影像	23
▲ 圖 4-7：BLIP Feature Extraction 向量化結果示意圖	25
▲ 圖 5-1：iMercury 系統研究成果總結示意圖	29
▲ 圖附錄 3-1：跨大語言模型標記一致性之提示詞設計準則	38

表目錄

▼	表 2-1：傳統方式、現有電子郵件自動管理系統與本研究 iMercury 系統之比較.....	6
▼	表 4-1：Bi-LSTM 模型各部門分類成效評估表.....	21
▼	表 4-2：Bi-LSTM 與 CNN 整體效能與運算效率對照表.....	21
▼	表 4-3：測試圖片基本資料.....	23
▼	表 4-4：Image Captioning 與 Ollama 實驗結果比較.....	24
▼	表 4-5：VQA 與 Ollama 異常問答結果比較表.....	24
▼	表 4-6：Image-Text Matching 實驗結果.....	25
▼	表 4-7：影像分析模組實驗執行成果.....	26
▼	表 4-8：可量化的模型評估指標.....	27
▼	表 5-1：本研究之主要貢獻與成果彙整.....	29

第1章緒論

1.1研究背景與動機

在數位轉型與永續發展（ESG）的全球浪潮下，金融機構正積極導入前瞻技術以優化營運效能。現行金融業已在智慧投顧、風控模型等領域取得顯著進展，但在「內部行政自動化」的最後一哩路——官方電子郵件管理，多數企業仍停留在人工處理階段。面對每日龐大的信件量，仰賴專責人員手動閱讀、分類與轉發，不僅造成重複性行政成本的浪費，更可能因人為判斷落差導致關鍵資訊遺漏或誤派，影響客戶滿意度與企業形象。

1.2研究問題與挑戰

傳統的人工郵件派發模式面臨多重嚴峻挑戰，首先是高度重複性作業導致人力成本高昂，使專業人員難以發揮實質業務價值；其次，處理速度受限於人工工時而導致作業效率低下，難以應對高峰期或即時回覆的需求。在品質控管方面，多樣化的信件內容極易造成誤分類，進而產生高錯誤率與營運風險；最後，由於過程缺乏量化紀錄，導致數據化管理匱乏，使管理層難以追蹤處理時效並掌握潛在的流程問題。

1.3研究目的

本研究旨在開發一套整合人工智慧應用之電子郵件自動管理守護神——iMercury 系統，透過整合 NLP、SAM 與 LLM 等多模態 AI 技術，並結合開源工作流程引擎 n8n，構建從「理解、生成到派送」的自動化流程。本研究不僅探討技術面的實踐可行性，亦從商業模式與永續營運角度分析其投資報酬率（ROI）及對綠色金融之貢獻。

1.4預期貢獻

本研究的預期貢獻涵蓋技術、實務與社會責任三大維度。在技術創新方面，成功提出一套結合多模態 AI 與自動化流程引擎的行政輔助系統架構，為智能化

行政管理奠定基礎；在實務應用上，透過實證分析具體證明 AI 介入行政流程後，可顯著提升 80% 的處理效率，有效優化企業營運效能；此外，本研究亦深化了 ESG 實踐，展示數位化轉型如何具體轉化為節能減碳效益，進而協助企業達成淨零轉型的永續發展目標。

第2章產業現況與需求分析

2.1產業背景與現況

隨著金融科技（FinTech）的普及，金融機構已廣泛導入人工智慧於風險控管與客戶服務等領域。然而，在內部行政自動化方面，多數企業仍處於初級階段。以官方電子郵件處理為例，目前多數銀行仍高度仰賴人工判讀，由專職人員每日登錄信箱、閱讀內容、篩選並轉發至相關部門。這種作業模式在面對大量且多樣化的郵件時，不僅耗費高昂人力成本，也難以滿足數位轉型下對於即時性與高效率的要求。

2.2痛點與需求分析

根據對金融及大型製造業的實務觀察，現行人工派信流程面臨四大核心挑戰。首先，專責人員長期處理重複性且低附加價值的郵件分類，導致人力成本高昂，使專業人力無法投入具實質價值的業務任務；其次，處理速度受限於人工判讀工時，形成作業效率瓶頸，難以應對高峰期需求並造成關鍵資訊處理延遲。此外，人工判斷易導致誤分類，進而引發營運風險與合規挑戰，直接損及企業形象與客戶滿意度；最後，由於管理數據缺失，缺乏系統化的紀錄與分析，使得管理層難以量化客服負荷並掌握潛在問題，限制了企業持續優化的空間。

2.3數位轉型與 ESG 驅動之需求

在永續金融與 ESG 治理的浪潮下，企業日益重視內部營運效率的提升。整合 AI 之電子郵件自動管理系統能透過智慧化分流，減少重複性文書作業，這不僅是技術端的優化，更符合「淨零轉型」中的節能減碳目標。因此，市場迫切需要一套具備「自動辨識、分類與派發」能力的智能解決方案，以強化企業的綠色數位化競爭力。

2.4現有電子郵件自動管理系統與本研究之比較

隨著企業數位轉型與營運效率提升需求日益增加，電子郵件管理已逐漸由傳統人工處理模式，轉向結合人工智慧與流程自動化之智慧型管理架構。傳統人工方式雖具備高度彈性，可由人員依實際情境進行判讀與應變，然而在面對大量且多樣化之郵件時，往往必須投入大量人力逐封閱讀、分類與轉寄，不僅導致處理效率低落，亦容易因判斷標準不一致而產生誤分類、延誤處理或資訊遺漏等問題。此外，人工流程通常缺乏結構化紀錄與後續分析機制，使管理者難以即時掌握郵件流量、案件分布與部門負荷情形。此種現象亦與本研究於前述章節所指出之產業痛點相互呼應。

近年來，全球市場已出現多種電子郵件自動管理系統，並分別朝向不同應用情境發展。例如，Microsoft Copilot for Outlook 較偏重於個人層級之郵件助理功能，官方說明顯示其可執行收件匣優先排序、郵件摘要、草稿生成與規則建立，但目前情境仍以個人工作郵箱為主，且部分 Copilot 場景不支援 shared mailbox。Front 則以共享信箱、團隊協作與 AI 輔助分流為核心，強調 shared inbox、AI-assisted triage、no-code rules engine、workflows 與 analytics，較適合多人共同處理客服或營運信箱之協作場景。Zendesk 則主要應用於客服工單處理，官方文件顯示其 intelligent triage 可自動偵測 intent、sentiment 與 language，並將結果轉為 tags，以支援 views、triggers、automations 與 reporting。

整體而言，現有市場解決方案確實已在郵件智慧化處理方面取得一定成果，但其設計重心多集中於個人郵件助理、客服支援或共享信箱管理等特定場景，對於企業內部行政郵件之跨部門自動分流與派送需求，仍未必能提供完整且高度客製化之支援。相較之下，本研究提出之 iMercury 系統，係以企業內部行政郵件自動管理為核心應用情境，強調從郵件接收、內容理解、部門判定、信箱查詢、轉寄處理到即時通知之全流程自動化。其系統架構整合自然語言處理、大語言模型、影像附件分析、部門知識庫、流程自動化引擎與即時通訊通知機制，使系統不僅能針對文字內容進行語意判讀，亦能處理圖片附件所傳遞之資訊，進而提升

多模態郵件處理之完整性。另一方面，透過本體論約束與知識庫限制輸出範圍，iMercury 可進一步降低模型幻覺與誤分類風險，使郵件分類結果更符合企業內部部門分工與行政流程需求。

此外，本研究之系統設計不僅止於郵件內容之辨識與分類，更進一步將分類結果與部門信箱資料進行整合，自動完成對應信箱查詢、標準化郵件重整、自動轉寄與即時通知，形成具備實際落地能力之智慧化工作流程。相較於現有市場系統多偏向單一功能強化或特定情境最佳化，iMercury 更強調多模態分析、知識約束、部門導向派發以及行政流程整合等功能，因此在企業內部行政自動化應用方面，展現出較高之完整性與可擴充性。此一設計不僅有助於降低人工作業負擔、提升郵件處理效率與分派準確性，亦能透過流程數位化與管理紀錄結構化，為後續營運分析、流程優化與 ESG 永續治理提供具體基礎。

為更清楚呈現傳統方式、現有市場系統與本研究系統之差異，本研究整理如表 2-1 所示之比較結果。由該表可知，傳統人工方式在彈性上雖具一定優勢，但在效率、規模化與一致性方面相對不足；現有市場系統雖已能支援摘要、分類、流程管理或協作等部分功能，然在企業內部行政郵件分派、多模態分析、知識庫約束及即時通知整合等面向，仍未若本研究系統來得完整。綜上所述，iMercury 不僅回應了現行人工郵件管理模式之主要缺失，亦補足現有系統於企業行政郵件自動化場景中的若干不足，具有作為企業智慧郵件管理與行政自動化平台之發展潛力。

由表 2-1 可知，傳統人工方式於電子郵件處理流程中，仍高度仰賴人工逐封閱讀、判讀、分類與轉寄。此種作業模式雖具備一定彈性，但在面對大量且多樣化之郵件時，往往伴隨處理效率低落、人力成本偏高、誤分類風險增加及缺乏可量化管理紀錄等問題，亦即本研究於前述章節所指出之主要實務痛點。

▼ 表 2-1：傳統方式、現有電子郵件自動管理系統與本研究 iMercury 系統之比較

比較項目	本研究 iMercury 系統	Zendesk	Front	Microsoft Copilot for Outlook	傳統人工 方式
支援影像附件語意分析	✓	×	×	×	×
降低 LLM 幻覺與誤分類風險	✓	△	×	×	×
結合企業知識庫限制輸出範圍	✓	△	△	×	×
可自動查詢部門信箱資料	✓	△	△	×	×
支援即時通訊平台通知	✓	△	△	×	×
可對應 ESG 與數位轉型需求	✓	△	△	×	×
支援部門／意圖導向路由	✓	✓	✓	×	×
自動分類／分流至對應單位	✓	✓	✓	×	×
可自動轉寄至正確信箱	✓	✓	✓	×	×
支援共享信箱／團隊協作	△	✓	✓	×	×
依郵件內容進行 AI 語意判讀	✓	✓	✓	✓	×
支援規則式或流程式自動化	✓	✓	✓	△	×
提供可追蹤之結構化紀錄與分析	✓	✓	✓	△	×
自動摘要郵件內容	✓	△	✓	✓	×
自動判定優先順序	△	✓	△	✓	×
適用於客服／工單導向情境	△	✓	✓	△	×
適用於企業內部行政郵件分派	✓	△	✓	△	△
需人工逐封閱讀與判斷	×	△	△	✓	✓

註：

1. 「△」表示該方法或系統僅部分具備該功能，或需透過額外設定、模組整合後方能實現。

2. 「×

相較之下，現有市場上之電子郵件自動管理系統，已逐步導入人工智慧與流程自動化技術，以提升郵件處理效率。其中，Microsoft Copilot for Outlook 較偏重於個人層級之郵件摘要、回覆草稿生成與優先排序；Front 著重於共享信箱、團隊協作與流程式管理；Zendesk 則主要應用於客服工單分類、案件分派及客戶支援流程優化。官方資料顯示，這些系統多已具備 AI 輔助摘要、分類或自動化能力，但其核心設計目標分別偏向個人 productivity、shared inbox collaboration 或 customer support triage，並非專門針對企業內部行政郵件之跨部門自動轉派。

本研究所提出之 iMercury 系統，則進一步整合自然語言處理、大語言模型、影像附件分析、部門知識庫、工作流程自動化及即時通訊通知等功能，不僅可依郵件內容自動判斷對應部門，亦可完成查表、轉寄、通知與紀錄整合等後續處理。


相較於傳統方式與現有系統，iMercury 在多模態分析、知識約束、部門導向派發及企業行政自動化整合方面，具有較完整且明確之應用優勢。

綜上所述，現有電子郵件管理系統雖已具備一定程度之智慧化功能，然多半著重於單一情境之應用最佳化；而本研究之 iMercury 系統，則係以企業內部行政郵件處理為核心場景，強調從郵件理解、分類判斷、部門對應、郵件派送到即時通知之全流程自動化，因而更能回應數位轉型、營運效率提升及 ESG 永續治理等多重需求。

第3章研究方法與系統架構

3.1研究方法


本系統核心架構整合了自然語言處理（NLP）進行意圖分析、影像分割模型（SAM）辨識照片/圖片附件內容，以及大語言模型（LLM）執行雙重校驗與摘要生成，並透過 n8n 自動化流程引擎實現全自動化轉寄電子郵件以及 LineBot 聊天機器人的即時訊息通知。



▲ 圖 3-1：本系統核心架構

如圖 3-1 本系統核心架構所示，本系統以電子信箱接收到新郵件作為觸發點，工作流程能自動進行資料提取，抓取郵件主旨與內文摘要，並將結構化的原始郵件資料輸入給 AI agent，讓其擔任核心決策角色，負責語意分析與部門判斷。隨後，AI 會結合外部資料庫中的表單內容，將判斷出的部門結果對應至表單中各負責人的信箱地址，實現資料與邏輯的解耦設計。在確定負責人信箱後，系統會自動封裝郵件內容，將原始郵件內容、AI 分析摘要及轉寄聲明進行整合，並依照預設格式編排郵件主旨，生成郵件草稿，以便同時寄送至相關信箱。此外，系統還會將郵件主旨與摘要透過 LINE 推播，確保管理者能即時監控並作出反應。整體流程不僅完成了郵件的自動分發與留存，也兼顧了高隱私性與即時性，構建出企業級的智能化自動工作流。

3.2系統架構: n8n 流程自動化



▲ 圖 3-2：n8n 流程自動化

如圖 3-2 n8n 流程自動化所示，本研究利用 n8n 建立一套自動化郵件分類與通知流程，使企業在收到外部郵件時，能夠自動判斷郵件內容、辨識負責部門，並將資訊即時轉送至對應單位，以降低人工判讀與分派郵件所需的時間成本。整體流程從電子郵件接收開始，結合雲端大型語言模型、部門資料查詢以及多通道通知機制，形成完整的智慧郵件處理流程。


工作流始於 Gmail Trigger 模組，該模組監測特定電子郵件入站事件，並作為工作流的啟動點。隨後，透過 Get a message 節點進行資料擷取，將非結構化的郵件文本轉化為結構化對象，包含主旨、正文及元數據（Metadata），為後續的語意運算提供輸入載體。

系統的核心邏輯由 AI Agent 節點承載。此節點配置了 OpenAI Chat Model，利用生成式預測技術對郵件意圖進行分類與摘要。為了提升回覆的準確性與業務關聯性，本系統引入了 Google Sheets 節點進行外部知識庫檢索。此步驟將 AI 提取的特徵與雲端試算表中的靜態數據進行比對與串接。隨後，資料流進入 Python Code 節點，透過程序化腳本進行數據清洗（Data Cleansing）與邏輯格式化。此階段的作用在於確保異構數據源在輸出前，已轉化為符合 API 標準的數據交換格式。

最終執行階段採用了並行處理架構，將結果分發至兩個主要渠道：電子郵件回饋機制和即時通訊整合。電子郵件回饋機制：系統首先透過 Gmail Draft 創建草稿以供人工校閱，隨後利用 Send a message 執行發信動作，完成通訊閉環。即時通訊整合：同步透過 HTTP Request 調用 LINE API 接口，將關鍵處理結果推送到即時通訊端，確保管理端能實時掌握系統運作狀態。

3.3系統架構: 文字處理--電子郵件文字特徵提取與部門分類模型

在電子郵件自動管理系統中，文字處理模組承擔了核心的決策任務。本研究以 Kaggle 開源之 Customer IT Support - Ticket Dataset 作為測試驗證基礎。整體文字處理系統架構主要分為資料輸入與預處理、大語言模型（Large Language Model, 以下簡稱 LLM）標記驗證、資料分布調整，以及深度學習分類引擎，如圖 3-3。



▲ 圖 3-3：基於大語言模型輔助與深度學習之郵件分類系統架構圖

3.3.1資料處理與分類架構萃取&AI 標記引擎與交叉驗證


在資料輸入與預處理階段，系統首先讀取以試算表格式儲存之原始客服信件資料，並透過正規表示式萃取「主旨」與「內文」等關鍵特徵欄位，將其合併以完整捕捉電子郵件情境。為降低非結構化口語及多語系交雜對模型判斷之干擾，

所有內容均統一翻譯成繁體中文。同時，系統執行分類架構萃取（Taxonomy Extraction），將預先定義之部門與對應標籤清單序列化並儲存於知識庫（Knowledge Base）中，為後續之受限推論奠定基礎。


為了確保後續供深度學習模型訓練的資料品質具備最高權威性，於研究中導入大語言模型 ChatGPT 與 Gemini 作為初始的分類與標記引擎。為避免模型產生具隨機性之多重答案，系統透過嚴格的超參數設定，強制模型於解析文本後給出單一且確定的預測結果。在提示詞工程（Prompt Engineering）上，將明確的部門定義、少樣本提示（Few-shot Prompting）與優先判斷規則編碼至模型中；並導入本體論約束（Ontology Constraint）機制，動態自知識庫調用專屬標籤清單作為限制條件，大幅降低幻覺與誤判率。最終，本研究採用「多重專家共識」策略，僅提取「原始資料標籤」、「ChatGPT 預測」與「Gemini 預測」三者完全一致的樣本作為「黃金標準（Golden Standard）」資料集，藉此排除語意模糊的噪音數據。

3.3.2 資料分布調整與採樣策略&深度學習分類器建構

進入深度學習模型建構前，經統計分析發現，篩選後的優質資料集呈現顯著的類別失衡現象（詳見圖 3-4）。其中，第一大類「技術支援」樣本數佔比 46.6%，在初步訓練時導致模型極易產生多數類偏見（Majority Class Bias），整體準確率因而受限。為修正此現象，本研究實施了差異化的「階梯式平衡」採樣策略：針對第一大類執行下採樣（Down-sampling）以收斂其主導權至 650 筆；第二大類「帳單與付款」為配合階梯式平衡之平滑度，微幅下採樣至 450 筆；對於樣本數較少之第三大類「產品支援」與第四大類「服務中斷」，則採用上採樣（Up-sampling）策略，透過物理複製原始資料將樣本量翻倍，調整後的樣本分布如圖 3-5。此舉使模型能更均勻地學習各部門的語意特徵，避免對單一類別的過度依賴。



▲ 圖 3-4：多重專家共識標記後之原始樣本數分佈圖




▲ 圖 3-5：實施階梯式採樣平衡後之訓練集樣本分佈圖

在取得高純度且平衡的訓練資料後，本研究分別建構了雙向長短期記憶模型（Bi-directional Long Short-Term Memory, 以下簡稱 Bi-LSTM）與卷積神經網路（Convolutional Neural Network, 以下簡稱 CNN）進行文字分類訓練。Bi-LSTM 旨在利用其遞迴特性捕捉郵件敘述中的長距離因果關係與前後文邏輯；而 CNN 則透過一維卷積層捕捉關鍵詞彙與短語特徵（N-grams），以此探討不同神經網路架構在客服郵件分類任務上的適用性與效能差異。

3.4系統架構：影像處理

3.4.1系統總體架構設計與數據流

圖 3-6 展示了本系統如何從接收用戶投訴開始，經過數據處理、AI 分析，最終給出驗證結果的完整路徑。它強調了 BLIP 模型作為核心分析模組，如何同時提供多種分析結果（匹配分數、圖像描述、問答結果）以輔助決策。



▲ 圖 3-6：系統整體架構及影像處理數據流

多模態模型的輸入品質直接決定了輸出的準確度。此模組負責將異質資料標準化：在影像處理部分，透過影像正規化與尺寸調整（Image Normalization & Resizing），消除不同使用者設備拍攝時的解析度差異與光影雜訊，確保送入神經網路的張量矩陣符合模型輸入標準；而在文本處理部分，執行文本清理與提示詞格式化（Text Cleaning & Prompt Formatting），將使用者非結構化的文字描述轉化為模型易於理解的標準化提示詞（Prompts）。


本系統採用 BLIP (Bootstrapping Language-Image Pre-training) 模型作為核心分析引擎。有別於單一任務模型，此模組被設計為能同時平行輸出三種維度的特徵資訊以輔助決策，首先是 ITM 分數 (Matching)，用以量化影像與特定文本的契合度。其次是影像描述 (Image Captions)，由模型主動生成影像的全局語義描述，提供上下文參考。最後則是視覺問答 (VQA Answers)，用以針對特定瑕疵細節進行邏輯推理與精準問答。

系統並非單純依賴單一 AI 輸出，而是設計了「基於規則的邏輯與閾值(Rule-Based Logic & thresholding)」模組。此舉在實務工程上極具意義，它能將多維度的 AI 輸出進行加權與條件判斷，有效降低偽陽性 (False Positives) 與偽陰性 (False Negatives)。

最終結果實作了雙軌分流機制，極高機率為正常的案件自動結案 (Verified: Normal)，以節省運營成本；而具備潛在風險的案件則標記並轉交人工覆核 (Flagged: Potential Defect)，在效率與準確率之間取得最佳平衡。

3.4.2基於 ITM 的瑕疵檢測詳細流程

圖 3-7 深入展示了專題中一個關鍵的技術細節：如何利用 BLIP 的圖像-文本匹配 (ITM) 功能來檢測瑕疵。它詳細描繪了從輸入圖像和對比文本提示 ("正常" vs. "瑕疵")，到計算匹配分數、比較分數並做出最終分類的完整計算過程。



▲ 圖 3-7：基於 ITM 的瑕疵檢測詳細流程圖

3.4.2.1特徵空間映射 (Feature Extraction & Embedding)

在 ITM 瑕疵檢測流程中，系統首先會將使用者上傳的商品影像與預先設計好的文字提示詞分別轉換成模型可以理解的特徵表示。影像端會先經過尺寸調整、

像素正規化與張量轉換，使不同手機、不同拍攝角度或不同解析度的照片，都能以一致的格式輸入 BLIP 模型。接著，BLIP 的影像編碼器會擷取影像中的外觀特徵，例如商品輪廓、顏色、材質紋理、刮痕、髒污、破損或異常區域等視覺線索。

文字端則會將檢測目標轉換為語意明確的提示詞，例如「商品外觀正常，沒有明顯瑕疵」與「商品存在刮痕、破損、髒污或異常瑕疵」。這些文字提示會透過文字編碼器轉換成語意特徵向量，代表不同判斷條件下的語意方向。透過此方式，系統不是只單純判斷影像中是否出現某個固定物件，而是將影像內容與「正常」及「瑕疵」兩種語意描述進行比較。

因此，特徵空間映射的核心目的，是將影像特徵與文字特徵放入同一個多模態語意空間中，使後續模型能夠計算兩者之間的關聯程度。當影像特徵越接近「瑕疵」提示詞的語意方向時，代表該影像越可能包含異常；反之，若影像特徵越接近「正常」提示詞，則代表該影像較可能為正常商品照片。

3.4.2.2 跨模態匹配評分 (Image-Text Matching Scoring)

完成影像與文字的特徵轉換後，系統會進入跨模態匹配評分階段。此階段會將同一張商品影像分別與不同的文字提示詞進行配對，並透過 BLIP 的 Image-Text Matching (ITM) 機制計算影像與文字之間的匹配程度。舉例來說，系統會同時計算影像與「正常商品」提示詞的匹配分數，以及影像與「瑕疵商品」提示詞的匹配分數。

在實作上，可將影像記為 I ，正常描述提示詞記為 T_{normal} ，瑕疵描述提示詞記為 T_{defect} 。系統會分別取得 $S_{\text{normal}} = \text{ITM}(I, T_{\text{normal}})$ 與 $S_{\text{defect}} = \text{ITM}(I, T_{\text{defect}})$ 兩個分數。其中， S_{normal} 表示該影像與正常狀態描述的相似程度， S_{defect} 則表示該影像與瑕疵狀態描述的相似程度。分數越高，代表影像內容與該文字描述越一致。

此評分方式的優點在於，它不需要只依賴人工設定的單一瑕疵特徵，例如只找刮痕或只找破洞，而是透過影像與文字語意的整體匹配，判斷影像更接近「正常」還是「異常」。因此，當使用者上傳的照片角度、光線或背景有所差異時，ITM 分數仍能提供一個語意層級的判斷依據，作為後續決策分類的重要參考。

3.4.2.3 基於動態閾值之決策邊界(Thresholding & Score Comparison)

取得正常分數與瑕疵分數後，系統會進一步進行分數比較與閾值判斷。若 S_{defect} 明顯高於 S_{normal} ，表示影像內容與瑕疵描述較為接近，系統會將該案件標記為「潛在瑕疵」。反之，若 S_{normal} 高於 S_{defect} ，且瑕疵分數低於安全範圍，則可判定該影像較可能為正常商品。

然而，在實際應用中，影像品質、拍攝光線、背景雜訊與商品種類都可能造成分數波動。因此，本研究不建議只使用固定閾值進行二分判斷，而是採用「相對分數差距」與「動態閾值」共同判斷。例如可計算 $\Delta S = S_{\text{defect}} - S_{\text{normal}}$ ，當 ΔS 大於系統設定的風險閾值 τ 時，代表瑕疵語意明顯強於正常語意，系統便將結果標記為 Flagged: Potential Defect；若 ΔS 接近 0，代表模型判斷不夠明確，則進入人工覆核流程，避免誤判。

此決策邊界設計能讓系統在效率與準確率之間取得平衡。對於明顯正常的案件，系統可自動歸類為 Verified: Normal，以降低人工審查成本；對於疑似瑕疵或分數差距不明顯的案件，則保留人工確認機制，以降低偽陽性與偽陰性的風險。整體而言，基於 ITM 的瑕疵檢測流程可將影像內容、文字語意與分數閾值結合，形成一套可解釋、可調整且適合實務應用的多模態瑕疵判斷方法。

第4章研究結果

4.1系統實作成果

本研究成功建置「iMercury」整合人工智慧應用之電子郵件自動管理系統，並完成影像分析、文字分析、郵件自動轉寄與即時通知等核心功能模組之串接。整體系統可由指定電子郵件信箱接收新郵件後，自動擷取信件主旨與內容摘要，進行語意分析與部門判斷，再依據部門對應表自動查詢收件信箱，完成郵件重整、轉寄與通知流程。此一流程證明本研究所提出之架構具備高度可行性，且可應用於企業行政自動化之實務場域。其流程設計與模組分工，與第 3 章所述之 n8n 工作流、文字分類模組及影像分析模組一致。

首先，在工作流的起始階段，需建立一個能夠持續監控指定電子信箱的新郵件觸發機制。為了讓系統能夠定期檢查是否有新郵件進入，本研究設定工作流每分鐘執行一次郵件檢查。由於郵件資料屬於受保護資訊，因此系統必須先取得該信箱的授權憑證，才能合法存取郵件內容。這項授權通常透過 Gmail OAuth 方式完成，需由管理者在 Google Cloud Platform 建立應用程式憑證，並授權 n8n 存取指定信箱。完成授權後，如圖 4-1 所示，工作流即可在偵測到新郵件時，自動擷取郵件主旨與內文摘要，作為後續分析依據。



▲ 圖 4-1：系統收到新電子郵件立即觸發機制

當郵件內容被擷取後，下一步是透過雲端大型語言模型判斷郵件應由哪個部門負責處理。由於郵件內容辨識涉及自然語言理解，因此本研究導入 OpenAI 雲端模型作為判斷引擎，讓系統能根據信件內容自動辨識其業務類型。為了使用此服務，需先至 OpenAI 平台申請 APIKey，作為工作流呼叫雲端模型服務的授權憑證。此金鑰的功能在於驗證使用者身分，確保工作流可以安全地將郵件內容送至模型進行分析。完成 APIKey 設定後，系統便可將擷取到的郵件主旨與內容傳送至語言模型，並要求模型根據預先定義的部門類別進行判斷，例如管理部、人事部、資訊部、行銷部、營業部、維修部與客服部等。模型分析後僅回傳最終判定的部門名稱，以利後續流程進行對應。


在取得部門分類結果後，系統需進一步找到該部門的聯絡信箱，因此工作流會連接至預先建立的雲端試算表資料庫。此資料庫記錄各部門名稱與其對應的電子信箱，作為郵件轉派依據。為了讓 n8n 能夠讀取試算表內容，需先設定 Google Sheets 的授權憑證，使工作流具備讀取雲端表單資料的權限。當語言模型回傳部門名稱後，系統便依據該名稱至試算表中搜尋對應資料，取得負責單位的電子郵件地址。此設計可將部門信箱資訊獨立管理，若日後組織架構或聯絡方式變動，只需更新試算表內容即可，不需重新修改工作流設定，提高系統維護彈性。

當部門信箱查詢完成後，工作流會進入郵件內容整理階段。由於原始郵件內容可能較為零散，因此系統需重新整理主旨與內文，使轉寄內容更符合內部處理需求。在此階段，系統會保留原始郵件主旨，並加入轉寄標記與部門資訊，讓收件單位能清楚辨識該郵件為系統自動轉派的案件。同時，郵件內文會重新整理為標準格式，包含原始郵件主旨、原始郵件內容以及提醒部門進行後續處理的通知文字，使部門在收到信件時能快速掌握事件內容與來源。

如圖 4-2 所示，完成郵件整理後，系統會自動建立轉寄郵件並發送至對應部門信箱。此步驟的目的在於將外部來信迅速分派給正確的內部單位，減少人工轉寄的時間延遲，使郵件能在最短時間內送達負責人員。透過自動發送機制，各部門在收到信件後即可立即展開後續處理流程，提升整體郵件處理效率。



▲ 圖 4-2：系統自動建立轉寄郵件並發送至對應部門信箱



▲ 圖 4-3：本研究加入 LINE Bot 即時通訊提醒功能

如圖 4-3 所示，除了電子郵件通知外，本研究亦加入即時通訊提醒功能，以提高訊息通知的即時性。當郵件完成分類並轉寄後，系統會同步透過 LINE Messaging API 發送通知訊息，提醒相關部門有新案件待處理。為了使用此功能，需先在 LINE Developers 平台建立 Messaging API Channel，並取得存取權杖作為 API 驗證憑證。完成設定後，工作流即可透過 HTTP 請求方式將通知內容推送至指定群組或聊天室。通知內容包含負責部門名稱、郵件主旨與郵件摘要，使相關人員即使未立即查看電子郵件，也能透過即時訊息得知新案件資訊，進一步提升通知效率。

綜合上述流程，本研究所建置的 n8n 自動工作流，從新郵件偵測開始，依序完成郵件擷取、語意判斷、部門查詢、郵件重整、自動轉寄與即時通知等步驟，形成一套完整的智慧郵件處理機制。透過雲端大型語言模型的導入，系統能自動理解郵件內容並完成部門分派，再結合雲端資料查詢與雙通道通知方式，大幅減少人工處理郵件的負擔，提高郵件分派效率與部門回應速度，達成企業郵件流程自動化的目標。

4.2文字分類模組效能評估

本文字分類模組針對經過 LLM 篩選與重抽樣策略處理後之資料集，進行深度學習分類器的成效量化與質性探討，並提供不同模型架構的選用建議。

4.2.1類別平衡對模型準確率之影響與量化指標

在結果整合與成效評估階段，系統將模型預測之核心部門與人工標註之真實解答進行比對，自動計算準確率（Accuracy）、精準率（Precision）及 F1-score 等評估指標。在實施採樣平衡前，模型存在嚴重的類別預測偏向；導入「下採樣多數類、上採樣少數類」策略後，各弱勢類別的識別率顯著上升，整體系統的預測穩定性獲得實質突破。以本研究最終選用之 Bi-LSTM 模型為例，其於測試集之整體準確率達到 0.77，各部門之詳細成效如表 4-1 所示。

▼ 表 4-1：Bi-LSTM 模型各部門分類成效評估表

部門類別	精準率 (Precision)	召回率 (Recall)	F1-分數 (F1-score)	測試樣本數 (Support)
帳單和付款	0.60	0.37	0.46	76
技術支援	0.65	0.88	0.75	142
服務中斷和維護	0.93	0.88	0.90	80
產品支援	0.97	0.82	0.89	106
整體平均 (Macro Avg)	0.79	0.74	0.75	404
加權平均 (Weighted Avg)	0.78	0.77	0.76	404

從分析數據可知，模型在「服務中斷和維護」(F1=0.90)與「產品支援」(F1=0.89)類別中展現極高識別能力；然而，「帳單和付款」類別之召回率 (Recall) 僅為 0.37，顯示該類別與「技術支援」間存在顯著的語意重疊。

4.2.2 Bi-LSTM 與 CNN 模型表現對比


為提供系統開發者依據不同應用場景進行決策，本研究對比了 Bi-LSTM 與 CNN 兩款架構。如表 4-2 所示，Bi-LSTM 在各項巨集指標 (Macro Avg) 上均全面優於 CNN，尤其在理解郵件長距離語意依賴上表現優異；相較之下，CNN 模型雖整體準確率較低 (0.70)，但其運算效率極高，每個訓練週期 (Epoch) 僅需約 2 秒，比 Bi-LSTM 快上近一倍。

▼ 表 4-2：Bi-LSTM 與 CNN 整體效能與運算效率對照表

模型 架構	整體 準確率 (Accuracy)	巨集精準 率(Macro Precision)	巨集召回 率(Macro Recall)	巨集 F1- 分數 (Macro F1)	訓練速度 (秒/Epoch)	最佳收斂輪 數(Epochs)
Bi- LSTM	0.77	0.79	0.74	0.75	約 4~5 秒	50(穩定收斂)
CNN	0.70	0.72	0.73	0.71	約 1.5~3 秒	25(提早停止)

進一步觀察兩模型於各部門之 F1-score 表現 (詳見圖 4-4)，可發現有趣的架構特性差異。在『服務中斷』與『產品支援』類別，兩者表現相近，顯示此類文本具備明確的特徵詞彙；然而在語意較為複雜的『技術支援』類別，Bi-LSTM 大幅領先 (F1=0.75 vs. 0.57)，顯示其具備較佳的前後文關聯建模能力，能處理長篇且具邏輯性的技術描述。

值得注意的是，CNN 在『帳單和付款』類別微幅勝過 Bi-LSTM (F1=0.51 vs. 0.46)。這印證了 CNN 易受 N-grams 局部特徵觸發的特性，當郵件中出現『費用、發票、扣款』等高度相關詞彙時，CNN 能快速捕捉並分類，但也因此產生較高的誤判率，將非帳務類的技術問題誤植入此類別。



▲ 圖 4-4：Bi-LSTM 與 CNN 於各部門之 F1-score 表現對照圖

4.2.3 錯誤分析與混淆矩陣探討

除了量化指標外，本系統亦透過錯誤分析單元自動生成混淆矩陣進行質性探討。由圖 4-5 之最終版 Bi-LSTM 混淆矩陣可見，矩陣對角線數值顯著，印證了模型之基礎分類效能。

(實際\預測)	帳單和付款	技術支援	服務中斷和維護	產品支援
帳單和付款	28	42	3	3
技術支援	10	125	4	3
服務中斷和維護	2	5	70	3
產品支援	4	10	5	87

▲ 圖 4-5：最終版 Bi-LSTM 模型之混淆矩陣熱力圖

然而，分析亦指出模型在「技術支援」與「帳單和付款」間存在誤判現象。此結果釐清了深度學習模型在語意重疊情境下的邊界限制——即當技術問題涉及

付費軟體或帳務爭議時，文本特徵將高度趨同。此發現不僅確認了當前系統的效能瓶頸，也為未來進一步擴充特徵詞庫或最佳化提示詞工程提供了具體的數據佐證。

4.3影像分析模組—BLIP 與 Ollama 影像處理實驗之執行成果

本實驗以單張破損手機圖片作為影像處理案例，測試圖片基本資料如表 4-3 所示。圖 4-6 中手機螢幕具有大面積裂痕，屬於肉眼可明確辨識之異常案例。本實驗目的在於驗證 BLIP 與 Ollama 是否能辨識圖片主體、描述破損狀態，並將圖片轉換為可比對的向量或匹配分數。

▼ 表 4-3：測試圖片基本資料

項目	內容
原始尺寸	720 × 960
圖片內容	手機放置於桌面上，螢幕有大面積裂痕與破碎痕跡
核心異常點	手機螢幕破裂
實驗定位	單張案例驗證，不作為完整資料集準確率評估



▲ 圖 4-6：實驗測試圖片--破損手機螢幕影像

4.3.1 Image Captioning 與 Ollama 實驗執行成果

Image Captioning 實驗的目的，是觀察模型是否能直接從圖 4-6 描述出「手機」與「破損」等關鍵資訊。BLIP Captioning 的輸出為「a broken iphone」，代表模型成功辨識圖片主體為手機，且能指出其破損狀態。不過 BLIP 的描述較短，較接近物件標籤或簡短摘要。

相較之下，如表 4-4 所示，Ollama 視覺語言模型的輸出較接近人類自然語言說明，能指出手機螢幕嚴重損壞、存在許多裂痕與碎片，並進一步推論可能導致螢幕功能失效。因此，從本實驗得知，BLIP 適合擔任影像基礎辨識模組，而 Ollama 則適合補強使用者可讀的異常原因說明。

▼ 表 4-4：Image Captioning 與 Ollama 實驗結果比較

模型/方法	輸入設定	實際輸出摘要	結果解讀
BLIP Captioning	384×384	a broken iphone	能辨識出破損手機，但描述簡短
Ollama gemma3:4b	原圖輸入	手機螢幕嚴重損壞，有許多裂痕和碎片	能產生較完整的中文異常說明

4.3.2 Visual Question Answering 與 Ollama 實驗執行成果

VQA 實驗的目的，是將影像描述任務轉換成問答任務，並以「這張照片中有沒有不正常的地方？」作為問題輸入。結果顯示，BLIP VQA 回答為「i don't know」，表示在本案例中，BLIP 對中文異常問題的回答不穩定，無法直接指出螢幕破裂。


Ollama 視覺語言模型則能明確回答圖片中存在異常，並指出手機螢幕嚴重破碎與裂痕。此結果顯示，若系統需要產生給使用者或管理者閱讀的中文異常說明，僅依賴 BLIP VQA 可能不足，應搭配其他視覺語言模型或規則式後處理。以上結果如表 4-5 所示。

▼ 表 4-5：VQA 與 Ollama 異常問答結果比較表

模型/方法	問題	實際輸出摘要	結果解讀
BLIP VQA	這張照片中有沒有不正常的地方？	i don't know	未能指出異常
Ollama gemma3:4b	這張照片中有沒有不正常的地方？	是的，手機螢幕嚴重破碎，呈現許多裂紋和碎片	能明確指出異常與原因

4.3.3 Feature Extraction 實驗執行成果

Feature Extraction 實驗不以產生文字描述為目標，而是將圖片轉換為可計算的高維特徵向量。本實驗使用 BLIP Feature Extractor，設定 mode 為 image，輸入尺寸為 224×224 。實驗結果顯示，BLIP 產生的影像特徵維度為 768，輸出向量形狀為 (1,768)。



▲ 圖 4-7：BLIP Feature Extraction 向量化結果示意圖

圖 4-7 代表由非結構化影像轉換為結構化向量，可供後續相似圖片搜尋、圖片附件分類、異常案例檢索或向量資料庫比對使用。對本系統而言，此功能可用於建立歷史異常附件特徵庫，當新郵件附件進入系統時，即可與過往案例進行相似度比對。

4.3.4 Image-Text Matching 實驗執行成果

Image-Text Matching 實驗使用兩組文字提示進行比較，分別為「正常的商品照」與「異常的商品照」。理論上，若破損手機圖片與「異常的商品照」匹配程度較高，系統即可將圖片標記為異常。

▼ 表 4-6：Image-Text Matching 實驗結果

比較項目	輸出結果	說明
正常的商品照	0.0000065831	與正常商品描述的匹配機率較低
異常的商品照	0.0000141245	與異常商品描述的匹配機率較高
最終判定	異常	程式邏輯判定異常描述分數略高於正常描述

需要注意的是，本實驗輸出格式原本僅顯示至小數點後四位，因此正常與異常的匹配機率皆顯示為 0.0000，但將輸出精度提高至小數點後十位，即可清楚看出「正常的商品照」匹配機率為 0.0000065831，「異常的商品照」匹配機率為

0.0000141245，由此結果得知，程式邏輯判定異常描述分數略高於正常描述。若從論文嚴謹度來看，後續應將輸出精度提高至小數點後八位或十位，並統一 ITM 標示，以清楚呈現兩組提示之間的分數差異。

4.3.5 影像分析模組實驗執行成果與後續補強方向

綜合上述結果如表 4-7 所示，本實驗發現 BLIP 適合擔任影像處理基礎模組，尤其在 Captioning、Feature Extraction 與 Image-Text Matching 任務中具有實用價值。然而，BLIP VQA 在中文異常問答情境下表現不穩定，因此若系統需要對使用者輸出自然語言解釋，應搭配 Ollama 視覺語言模型或其他中文表現較佳的多模態模型。

▼ 表 4-7：影像分析模組實驗執行成果

模型/方法	是否指出異常	是否能說明原因	是否適合直接給使用者看	備註
BLIP Captioning	是	部分	普通	輸出 a broken iphone，能指出破損手機
BLIP VQA	否	否	不適合	回答 i don't know，本案例中文異常問答不穩定
BLIP Feature Extraction	不直接判斷	不適用	不適合直接閱讀	輸出 768 維向量，適合做檢索與比對
BLIP Image-Text Matching	是	否	普通	可做正常/異常相對判定，但需提高分數精度
Ollama gemma3:4b	是	是	適合	能產生完整中文異常說明

本實驗顯示 BLIP 可辨識破損手機並輸出 768 維向量，且可透過文字匹配做初步異常判斷，但若要進一步量化模型表現，需建立多張正常與異常圖片資料集，並加入人工標註進行正式評估；此外，為了提高 Image-Text Matching 分數輸出精度，至少顯示至小數點後八位，以便觀察正常與異常提示的差異，再如表 4-8 所示，加入 Accuracy、Precision、Recall、F1-score 與混淆矩陣，建立可量化的模型評估結果，並針對中文 VQA 進行提示詞優化，或測試其他多模態模型，以提升中文問答穩定性；最後，將上述 BLIP 產生的 768 維向量寫入向量資料庫，建立圖片附件相似案例檢索功能。

▼ 表 4-8：可量化的模型評估指標

評估指標	計算方式	用途
Accuracy	$(TP + TN) / (TP + TN + FP + FN)$	整體分類正確率
Precision	$TP / (TP + FP)$	模型判定為異常的圖片中，有多少是真正異常
Recall	$TP / (TP + FN)$	所有真正異常圖片中，有多少被模型找出
F1-score	$2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$	平衡 Precision 與 Recall 的綜合指標

第5章結論

本章綜整前述研究背景、系統架構、模型設計與實驗結果，對「iMercury」整合人工智慧應用之電子郵件自動管理系統之研究成果、學術與實務貢獻、研究限制及未來發展方向進行統整說明。

5.1研究結論

本研究針對企業內部行政郵件長期仰賴人工閱讀、判讀、轉寄與通知之問題，提出一套以 iMercury 為核心之智慧化自動管理系統。系統整合自然語言處理、大語言模型、知識庫約束、影像分析模組與 n8n 流程自動化機制，使郵件自接收起即可完成內容擷取、部門判定、信箱查詢、郵件重整、自動轉寄與 LINE 即時通知，形成具備實際落地能力之端到端行政自動化流程。

在文字分類方面，本研究以 Kaggle Customer IT Support - Ticket Dataset 為基礎，先透過 LLM 標記驗證、多重專家共識與階梯式平衡採樣策略建立較高純度之訓練資料，再分別建構 Bi-LSTM 與 CNN 分類器進行比較。實驗結果顯示，Bi-LSTM 模型整體準確率達 0.77，巨集 F1-score 為 0.75，整體表現優於 CNN，且於「服務中斷和維護」與「產品支援」類別具有較高辨識能力，顯示本研究所提出之資料建構流程與模型設計具備可行性與實際效益。

在影像分析方面，本研究以 BLIP 為核心，結合 Image-Text Matching、Image Caption 與 VQA 多重訊號，並透過規則式邏輯與動態閾值進行決策融合，使系統得以在正常案件自動結案與疑似瑕疵案件人工覆核之間取得平衡。此設計說明多模態方法不僅能補足純文字分類之侷限，也有助於提升實務場域中對圖片附件與申訴證據之判讀能力。

綜合系統實作與論文各章結果，本研究證明 iMercury 不僅可有效回應傳統人工派信流程之效率瓶頸與誤分類風險，亦可提供企業在數位轉型、知識化管理與 ESG 治理上的具體技術路徑。系統預期可提升郵件處理效率達 80% 以上，並降低誤判率約 70%，顯示人工智慧導入行政郵件流程具有高度應用潛力。

5.2 研究貢獻總結



▲ 圖 5-1：iMercury 系統研究成果總結示意圖

▼ 表 5-1：本研究之主要貢獻與成果彙整

面向	具體成果	意義說明
技術架構	整合 NLP、LLM、BLIP、知識庫與 n8n	建立可同時處理文字與影像附件之多模態郵件管理流程。
系統實作	完成郵件擷取、部門判定、查表、轉寄與 LINE 通知	證明研究不僅停留於模型層面，而且具備企業導入之工作流可行性。
文字分類	Bi-LSTM 準確率 0.77、Macro F10.75	顯示經 LLM 輔助標記與平衡採樣後，可有效提升部門分類穩定性。
影像分析	BLIP+ITM+規則式決策融合	提供圖片附件案件的可解釋判斷依據，補強單純文字分類不足。
管理價值	處理效率提升 80%+誤判率降低 70%	具備降低人力成本、強化流程透明度與支援 ESG/數位轉型之潛力。

由表 5-1 可知，本研究之貢獻不僅在於提出一套具體可運作之技術架構，更在於透過「資料前處理—知識約束—模型分類—工作流程執行—通知與留存」之整體設計，將生成式 AI 與企業行政流程有效銜接。相較於僅提供摘要、回覆建議或客服工單分流之既有系統，iMercury 更強調企業內部行政郵件場景之部門導向派發與多模態判讀。

因此，本研究可視為一項兼具學術探索與實務導入價值之專題成果：在學術層面，證明 LLM 輔助標記、平衡採樣與深度學習分類之整合策略具研究意義；在實務層面，則驗證 AI agent 與流程引擎之結合，可將原本耗時的人工行政流程轉化為可追蹤、可擴充、可維護的智慧工作流。

5.3研究限制

首先，本研究之文字分類資料來源為客服工單資料集，雖已透過翻譯、標記驗證與知識庫限制提升資料品質，但其部門類別與語意分布仍與特定企業之真實行政信箱內容存在差異。因此，若系統正式部署於不同產業場域，仍需依企業實際組織架構、業務術語與郵件型態進行再訓練或規則微調。

其次，在文字分類模型表現上，雖 Bi-LSTM 已獲得較佳整體結果，但「帳單和付款」與「技術支援」之間仍存在語意重疊與錯判現象，顯示部分類別邊界尚未完全清晰。此問題反映出複雜行政郵件在真實世界中常具跨部門特性，單一標籤分類在某些情境下可能不足。

再者，在影像分析模組方面，本研究以 BLIP 為核心並透過單案示範驗證其流程合理性，但影像資料量與品類規模仍有限，尚未形成大規模、多類別、多情境之系統化測試。因此，影像判讀模組目前較適合作為輔助判斷機制，而非完全取代人工覆核。

最後，本研究系統目前以雲端模型與雲端服務整合為主，雖有利於快速驗證概念與縮短開發時間，但在高度敏感之企業資料環境中，仍須進一步處理模型部署位置、權限控管、稽核紀錄與資訊安全等議題。

5.4未來研究方向

未來研究可由四個方向持續深化。其一，於資料層面擴充真實企業郵件語料，並建立更細緻之多層級部門—任務—優先級標籤架構，以支援多標籤分類與更精準的路由決策。其二，於模型層面可進一步比較 Transformer 類分類器、指令微調模型或 Retrieval-Augmented Generation 架構，以提升長文本理解、語意消歧與跨部門郵件判讀能力。

其三，於多模態層面可擴充更多影像案例、結合 OCR 與檔案類型辨識，使系統除處理純文字與照片外，亦能解析掃描文件、發票、報修影像與截圖附件，

形成更完整之企業行政 AI agent。其四，於系統層面可評估導入地端大型語言模型、權限管理模組、日誌追蹤機制與儀表板分析介面，以回應企業對隱私保護、資訊安全與治理透明度之需求。

總體而言，iMercury 未來可由「電子郵件自動分派系統」進一步發展為「企業行政流程智慧協作平台」。若能持續結合知識工程、多模態 AI 與流程治理設計，將有機會在金融、製造、客服、校務與公部門等場域發揮更大應用價值。

参考文献

- [1] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A. C., Lo, W.-Y., Dollár, P., & Girshick, R. (2023). Segment Anything. arXiv preprint arXiv:2304.02643. <https://arxiv.org/abs/2304.02643>
- [2] Li, J., Li, D., Xiong, C., & Hoi, S. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. arXiv preprint arXiv:2201.12086. <https://arxiv.org/abs/2201.12086>
- [3] Li, J., Li, D., Savarese, S., & Hoi, S. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. arXiv preprint arXiv:2301.12597. <https://arxiv.org/abs/2301.12597>
- [4] n8n. (2026). n8n documentation. Retrieved May 18, 2026, from <https://docs.n8n.io/>
- [5] n8n. AI Workflow Automation Platform. Retrieved May 18, 2026, from <https://n8n.io/>
- [6] Bueck, T. (n.d.). Customer IT support - Ticket dataset. Kaggle. Retrieved May 18, 2026, from <https://www.kaggle.com/datasets/tobiasbueck/multilingual-customer-support-tickets>
- [7] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language models are few-shot learners. In Advances in Neural Information Processing Systems, 33, 1877–1901. <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- [8] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT 2019 (pp. 4171–4186). Association for Computational Linguistics. <https://aclanthology.org/N19-1423/>
- [9] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems, 30. <https://papers.neurips.cc/paper/7181-attention-is-all-you-need>
- [10] Google. (2026). Google Sheets API documentation. Google for Developers. Retrieved April 27, 2026, from <https://developers.google.com/workspace/sheets/api/guides/concepts>

- [11] LINE Corporation. (2026). Messaging API documentation. LINE Developers. Retrieved April 27, 2026, from <https://developers.line.biz/en/docs/messaging-api/>
- [12] OpenAI. (2026). OpenAI API platform documentation. Retrieved April 27, 2026, from <https://platform.openai.com/docs>
- [13] Ruan, Q., Kuznetsov, I., & Gurevych, I. Are Large Language Models Good Classifiers? A Study on Edit Intent Classification in Scientific Document Revisions. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, 15049–15067. Association for Computational Linguistics. 2024. <https://doi.org/10.18653/v1/2024.emnlp-main.839>
- [14] Mirza, P., Sudhi, V., Sahoo, S. R., & Bhat, S. R. ILLUMINER: Instruction-tuned Large Language Models as Few-shot Intent Classifier and Slot Filler. In Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), 8639–8651. 2024. <https://aclanthology.org/2024.lrec-main.758/>
- [15] Vukovic, R., Arps, D., van Niekerk, C., Ruppik, B. M., Lin, H.-C., Heck, M., & Gašić, M. Dialogue Ontology Relation Extraction via Constrained Chain-of-Thought Decoding. In Proceedings of the 25th Annual Meeting of the Special Interest Group on Discourse and Dialogue (SIGDIAL 2024). 2024. <https://doi.org/10.48550/arXiv.2408.02361>
- [16] Park, K., Wang, J., Berg-Kirkpatrick, T., Polikarpova, N., & D’Antoni, L. Grammar-Aligned Decoding. In Advances in Neural Information Processing Systems, 37. 2024. <https://doi.org/10.48550/arXiv.2405.21047>
- [17] Ravi, N., Gabeur, V., Hu, Y.-T., Hu, R., Ryali, C., Ma, T., Khedr, H., Rädle, R., Rolland, C., Gustafson, L., Mintun, E., Pan, J., Alwala, K. V., Carion, N., Wu, C.-Y., Girshick, R., Dollár, P., & Feichtenhofer, C. SAM 2: Segment Anything in Images and Videos. arXiv preprint arXiv:2408.00714. 2024. <https://doi.org/10.48550/arXiv.2408.00714>
- [18] Özdemir, Ö., & Akagündüz, E. Enhancing Visual Question Answering through Question-Driven Image Captions as Prompts. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 1562–1571. 2024.

https://openaccess.thecvf.com/content/CVPR2024W/PV/html/Ozdemir_Enhancing_Visual_Question_Answering_through_Question-Driven_Image_Captions_as_Prompts_CVPRW_2024_paper.html

- [19] Su, H., Luo, W., Han, W., Liu, Y., Zhang, Y., Zhao, C., Zhang, J., & Mehdad, Y. LLM-Friendly Knowledge Representation for Customer Support. In Proceedings of the 31st International Conference on Computational Linguistics: Industry Track, 496–504. Association for Computational Linguistics. 2025. <https://aclanthology.org/2025.coling-industry.42/>
- [20] Liu, F., He, X., Zhang, T., Chen, J., Li, Y., Yi, L., Zhang, H., Wu, G., & Shi, R. TickIt: Leveraging Large Language Models for Automated Ticket Escalation. In Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering. 2025. <https://doi.org/10.1145/3696630.3728558>
- [21] Alekseev, I., Solomatin, R., Rustamova, D., & Kuznetsov, D. AutoIntent: AutoML for Text Classification. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 707–716. Association for Computational Linguistics. 2025. <https://aclanthology.org/2025.emnlp-demos.53/>

附錄：

1. 專案時程與組織分工

1.1 專案時程

月份	114/7	114/8	114/9	114/10	114/11	114/12	115/1	115/2	115/3	115/4	115/5
項目											
Keras深度學習	書籍研讀										
專題主題訂定											
文字處理			相關文獻資料學習	資料集蒐集與模型訓練調整							
圖片處理			相關文獻資料學習	模型訓練調整							
n8n			地端架設、介面熟悉與學習	工作流建立與調整							
報告書			歷屆作品參考與研讀							報告書製作	

1.2 組織分工

項目/組員	余明憲	吳彥瑾	吳奕萱	張育馨	葉佳穎
電子郵件分類			◎		
影像描述		◎			
n8n 工作流製作				◎	◎
文件製作	◎				

2. 評審意見回覆

評審委員意見	本組回覆
1. 流程裡面有，但是展示的時候沒有看到草稿的回覆信，是只有構想而已，還是真的有做到這個部分？其次是已經有通知各部門了，如果可以再提供各單位回覆郵件的草稿，可以讓各單位回覆郵件更有效率。（育馨&佳穎）	謝謝委員提問及提供寶貴的意見。依目前 n8n 工作流的設計是以不靠人力全自動轉寄為目的，所以工作流會在儲存草稿後直接轉寄出去。 若期望可以先將回復儲存成草稿後由負責人或管理人先行審查修改再寄出，可藉由修改工作流來達成；也可以依據特殊要求在工作流中設計分流節點，將郵件分類成可直接轉寄出、需待審查後寄出等等，依據分類特性在工作流設計出相對應的後續執行動作。未來如建立本地端的知識庫，可根據來信內容自動生成回覆的郵件草稿，提供給各單位承辦人員參考。
2. 目前大型語言模型的 Token 使用成本與耗電量越來越高，團隊是否有想到節省 Token 的方法，以更符合報告中提及的 ESG（環境保護與節能減碳）訴求？（奕萱）	謝謝委員提供寶貴的意見。針對 ESG 訴求，導入本系統後將可大幅減少人工逐封閱讀之無效工時，具體落實公司治理(Governance)與數位轉型之效能提升。在節省 Token 成本方面，本系統於資料預處理階段導入「語言統一」機制，先行透過 Google Translate 將各種語言統一翻譯為繁體中文，此舉不僅能減少混合語言環境之干擾，更能有效控制送入大語言模型之 Token 數量與運算複雜度，未來本系統導入本地端模型(Local LLM)後，即可獨立運作，不需要另外負擔雲端運算的費用，進而節省系統運作的成本。

3. 影像處理是比較難的部分，可以用 LLM 來做，也可以像我們這裡提到的方法來做，這裡目前只有用一個破碎的手機螢幕的例子，回覆影像辨識結果的文字也相符，但如果還有其他各類的影像的案例，有影像也有文字，你們要怎麼來處理?(彥瑾&明憲)	謝謝委員提問。有影像也有文字的案例，都處理可以透過「影像處理模型 + 文字處理模型」整合完成。影像模型負責辨識圖片內容，但提供的文字說明可能不夠詳盡，而加入 LLM 負責理解與產生文字說明，像是圖片分類、物件偵測、OCR 文字辨識、影像問答等，都可以取得較佳的文字說明內容，而用這種方式實作所獲得的成果將會是比較好的。
4. 請說明論文第 11 頁提到的本體論約束 (Ontology Constrain) 機制。(奕萱)	謝謝委員提問。本團隊於資料處理階段執行「分類架構萃取(Taxonomy Extraction)」，將預先定義好的部門與標籤清單序列化儲存於知識庫中，在呼叫大語言模型時，系統透過提示詞工程(Prompt Engineering)強制要求標籤必須從上述對應部門的清單中挑選，若無合適標籤請給空陣列，藉由動態調用外部知識庫做為限制條件，系統能有效限縮模型輸出範圍，大幅降低 AI 幻覺與誤分類風險。
5. 經過樣本採樣調整後，各部門的資料量排序與原始分佈產生了變化，這樣的比例與排序改變，是否會對實證結果產生負面影響?(奕萱)	謝謝委員提問。關於採樣導致的排序變化與影響，這確實是機器學習中常面臨的「真實分佈」與「訓練分佈」的取捨問題。 ● 避免多數類偏見：若維持原始排序與比例直接訓練，模型會傾向直接猜測佔比最大的「技術支援」類別，導致模型對少數類別毫無辨識能力，整體準確率因而受限。 ● 實證結果展現顯著提升：改變排序與比例的目的是為了「使模型能更均勻地學習各部門的語意特徵，避免對單一類別的過度依賴」。根據本研究的實證結果，在實施階梯式採樣平衡後，模型在原先樣本極少的「服務中斷和維護」(F1-score = 0.90)與「產品支援」(F1-score = 0.89)類別上，展現了極高的識別能力。
6. 簡報第 25 頁請說明一下上採樣(Up-sampling)與下採樣(Down-sampling)是怎麼做的?(奕萱)	謝謝委員提問。本系統在初步篩選資料後，發現原始資料存在極嚴重的類別失衡現象（例如「技術支援」佔比高達 46.6%）。為了進行調整，本團隊實施了「階梯式平衡」採樣策略： ● 下採樣：針對資料量過大的第一大類「技術支援」，我們隨機刪減樣本以收斂其主導權至 650 筆；第二大類「帳單與付款」則為配合階梯式平衡的平滑度，微幅下採樣至 450 筆。 ● 上採樣：針對樣本數較少的第三大類「產品支援」與第四大類「服務中斷和維護」，我們採用的具體作法是「物理複製原始資料」將其樣本量翻倍，從原本的 272 筆與 187 筆，分別提升至 544 筆與 374 筆。以此方式彌補弱勢類別的特徵數量。

7. 簡報第 38 頁當中的圖顯示 BLIP(處理數據)為何要切換到 Bert?(彥瑾&明憲)	謝謝委員提問。BLIP 是整體視覺語言比對模型；BERT 是 BLIP 中負責文字 prompt 編碼的語言模組。圖片由 ViT 編碼，文字由 BERT 編碼，最後由 BLIP 的 ITM 模組計算圖片與文字的匹配分數。整個流程不是在 BLIP 和 BERT 之間切換，而是兩者分工合作：ViT 看圖、BERT 讀文字、ITM 做圖文配對，最後用分數門檻決定產品是正常或瑕疵。
8. 簡報第 31 頁當中的圖，為什麼不直接用 BERT，還要用 BLIP 分別處理 ITMScores, Image Captions, VQA Answers?(彥瑾&明憲)	謝謝委員提問。附圖不直接只使用 BERT，是因為 BERT 本質上是文字模型，無法直接檢查產品圖片中的實際瑕疵。BLIP 則能整合 ViT 的視覺特徵與 BERT-like 文字編碼能力，因此可以同時產生三種互補訊號： ITM Scores：判斷圖片與瑕疵描述是否匹配； Image Captions：將圖片內容轉換成自然語言描述； VQA Answers：針對具體瑕疵問題提供答案。 三種結果再進入 Decision Fusion 模組，可降低單一模型輸出的誤判風險。從系統設計角度來看，最合理的做法不是以 BLIP 完全取代 BERT，而是讓 BERT 負責純文字理解，BLIP 負責圖片與文字的多模態分析。
9. 個人為什麼不想採用本系統，最大的原因是把個人資料傳到 LLM 處理完再送回來，感覺會有個資外洩的疑慮，也許部分內容可以用這套系統，但是有些內容就不適合。(明憲)	謝謝委員提供寶貴的建議。本系統是以建置本地端 LLM 來處理所有的資料為最終的系統運作模式，現階段開發系統時，因考量實際硬體建置成本，所以是以雲端 LLM 來處理資料，未來如有硬體配合本地段 LLM，就沒有把個人資料傳到雲端處理後再回傳，有可能造成個資外洩的疑慮。
10. 你們這組的實作能力很強，但缺點是文獻回顧缺乏最近 2 年的內容，應該要再補充 2024 到 2025 的文獻。(明憲)	謝謝委員提供寶貴的建議。本論文為 2025 年底到 2026 年初的研究，故新增收錄近兩年的論文共 9 篇進參考文獻中。
11. 影像處理的例子只有 1 個，應該要開發更多圖片，而且考量成本效益的問題，處理圖片所需的 token 要比較多，如果用人工處理圖片部分是不是就可以了?其他文字的部分再利用 LLM 來處理。(明憲)	謝謝委員提問並提供寶貴的建議。本系統規劃在未來陸續加入 OCR、附件類型辨識與多模態檢索，而本系統建置最終就是要建立本地端的 LLM，因此不會有消耗大量 token 才能處理郵件的問題。

3. 其他相關資料

3.1 附錄圖-跨大語言模型標記一致性之提示詞設計準則

```
SYSTEM_PROMPT = """
你是一個專業的客服工單分類AI。

你的任務是根據 ticket 的「主旨(subject)」與「內容(body)」，
從下列部門選單中選出 **最適合的一個部門**，並挑選對應的 **標籤**。
```

=====

【分類選單與定義】

=====

1. [技術支援]：外部客戶遇到 **技術錯誤或系統問題**。
2. [客戶服務]：客戶帳號或訂單相關問題。
3. [帳單和付款]：與金錢或帳務相關問題。
4. [產品支援]：產品 **使用方式或功能問題**（不是壞掉）。
5. [IT支援]：公司「內部員工」IT問題。
6. [退貨和換貨]：產品需要退回或更換。
7. [銷售和售前]：客戶在購買前的問題。
8. [人力資源]：員工或求職相關問題。
9. [服務中斷和維護]：系統大規模服務中斷或維護。
10. [一般詢問]：沒有明確技術問題的普通詢問。

=====

【判斷規則】

=====

優先判斷：

- 1 如果內容提到 付款 / 發票 / 扣款 → [帳單和付款]
- 2 如果是 公司內部員工 IT 問題（例如 VPN / access / office）→ [IT支援]
- 3 如果是 客戶系統錯誤 / bug / login error → [技術支援]
- 4 如果只是 詢問如何使用產品 → [產品支援]
- 5 如果是 整個系統不能用 / 網站掛掉 → [服務中斷和維護]
- 6 如果是 詢價或購買問題 → [銷售和售前]
- 7 如果提到 return / exchange / RMA → [退貨和換貨]
- 8 如果與 招聘 / 員工問題 → [人力資源]
- 9 如果是 帳號問題或客戶服務流程 → [客戶服務]
- 10 如果只是 一般問題且沒有明確技術或帳務問題 → [一般詢問]

若資訊不足，預設分類：

[一般詢問]

=====

【各部門可用標籤清單】

=====

{schema_str}

=====

【強制輸出格式】

=====

你必須以純 JSON 格式輸出，不要包含任何 Markdown 標記（不要用 ```json 包裝）。格式如下：


```
{{
  "department": "請填寫一個部門名稱，必須包含中括號，例如 [技術支援]",
  "tags": ["標籤1", "標籤2"]
}}
```

注意：標籤必須從上述對應部門的清單中挑選，若無合適標籤請給空陣列 []。

```
"""
```

▲ 圖附錄 3-1：跨大語言模型標記一致性之提示詞設計準則

3.2 參賽證明: 參與「2025 第五屆 AI 金融科技創新創意競賽綠色金融永續淨零組」



3.3 論文發表證明：參與「2026 創新設計實務研討會」論文發表

