

國立臺北商業大學

資訊管理系 人工智慧科技應用學士後專班

115 AI資訊專題研究報告

題目：“iMercury”——整合人工智慧應用之電子郵件

自動管理系統

組別：第 P11303 組

第一指導老師：蒯思齊 老師

第二指導老師：蔡文隆 老師

組長：P1136104 余明憲

組員：P1136105 吳彥瑾 P1136110 吳奕萱

P1136122 張育馨 P1136129 葉佳穎



參與「2025第五屆AI金融科技創新創意競賽綠色金融永續淨零組」競賽



參與「2026創新設計實務研討會」論文發表

創新設計實務研討會

Conference on Innovation and Design



論文發表證明

蒯思齊,余明憲,吳彥瑾,吳奕萱,張育馨,葉佳穎,廖文華

論文題目

整合人工智慧應用之電子郵件自動管理系統

於中華民國 115 年 5 月 15 日

參加「2026 創新設計實務研討會」特此證明



致理科技大學
Chihlee University of Technology



創新設計學院
College of Innovation and Design

王 年 傑

創新設計學院 院長

目錄 CONTENT

01 研究背景與動機

02 系統架構

● n8n流程

● 文字處理

● 影像處理

03 研究成果總結

04 參考文獻

研究背景與動機

報告人：余明憲

產業現況概述

在數位轉型與永續發展（ESG）的全球浪潮下，金融機構正積極導入前瞻技術以優化營運效能。現行金融業已在智慧投顧、風控模型等領域取得顯著進展，但在「內部行政自動化」的最後一哩路——官方電子郵件管理，多數企業仍停留在人工處理階段。面對每日龐大的信件量，仰賴專責人員手動閱讀、分類與轉發，不僅造成重複性行政成本的浪費，更可能因人為判斷落差導致關鍵資訊遺漏或誤派，影響客戶滿意度與企業形象。

研究動機：人工郵件派發是行政自動化的最後一哩路

從人工判讀到智慧分流：降低等待、誤派與資料斷點

80%+

處理效率預期提升

70%

誤判率預期降低

5 steps

端到端流程

Email + LINE

多通道通知

- 金融與大型企業已導入 AI 於風控與客服，但內部行政信箱仍多仰賴人工處理。
- 重複性閱讀、分類、轉寄造成時間成本與關鍵資訊延誤。
- 缺乏結構化紀錄，使管理端難以量化案件流量與部門負荷。
- ESG 與數位轉型要求企業流程更即時、可追蹤、可持續改善。

研究目的與系統定位

建構一套適合企業內部行政郵件的智慧化自動管理架構

核心目標：讓系統從「理解郵件內容」一路推進到「自動派送與即時通知」，不只做摘要，而是完成流程閉環。

- NLP / LLM：分析郵件主旨與內文，推論部門與處理方向。
- 知識庫約束：以部門與標籤清單限制輸出，降低幻覺與誤分類。
- n8n 工作流：串接 Gmail、OpenAI、Google Sheets、Python 與 LINE API。
- 多模態擴充：以 BLIP / VLM 處理圖片附件，支援異常案件判讀。



現有方法比較：本研究聚焦企業內部行政郵件分派

與個人助理、共享信箱、客服工單系統形成差異化

比較面向	iMercury	Copilot	Front	Zendesk	傳統人工
自動分類／分流	✓	✗	✓	✓	✗
影像附件語意分析	✓	✗	✗	✗	✗
知識庫限制輸出	✓	✗	△	△	✗
部門信箱查表與轉寄	✓	✗	△	△	✗
LINE 即時通知整合	✓	✗	△	△	✗
企業行政郵件適用性	✓	△	✓	△	△

✓ = 核心功能；△ = 部分具備或需整合；✗ = 非主要設計特徵


結論：iMercury 的差異點不是單一 AI 功能，而是「語意判讀 → 知識約束 → 部門對應 → 郵件派送 → 即時通知」的整體流程整合。

系統架構

報告人：張育馨

系統核心架構：從新郵件到雙通道通知

AI agent 擔任決策核心，n8n 負責流程編排與執行



- 郵件內容進入 AI agent，完成摘要與部門分類。
- Google Sheets 保持部門信箱資料可維護。
- 系統同時完成郵件轉寄與 LINE 即時提醒。

n8n工作流流程

報告人：張育馨、葉佳穎

全自動化 workflow 五大階段



1. 觸發提取

實時監測電子信箱，自動提取主旨與內文核心資訊。



2. 語意分析

AI Agent 進行深度語意分析，判斷對應部門類別。



3. 資料解耦

結合外部資料庫與表單，精確匹配負責人信箱。



4. 自動轉寄



整合摘要與原文，自動封裝並生成轉發郵件草稿。



5. 同步監控

整合 LINE Bot 實時推播，確保管理層即時掌握動態。

第一階段： 郵件接收與郵件資訊提取



以收到的新郵件為觸發點

由電子信箱收到新郵件作為觸發點，
工作流會自動進行資料提取、抓取主旨與內文摘要。

核心邏輯：以郵件為驅動核心





自動化觸發機制 workflow 實時監控電子信箱，當收到新郵件時即刻啟動後續流程。





關鍵資料提取 精確抓取郵件主旨、發件人、日期及內文摘要，為 AI 分析準備數據。



技術實踐重點 需於 Google Cloud Platform 建立專案並設定 API Key，取得憑證後於 n8n 完成認證授權。



第二階段： AI agent進行語意分析與部門判斷



AI agent進行語意分析與部門判斷


將結構化的原始郵件輸入資料，交給 AI agent 擔任核心決策角色以進行語意分析與部門判斷。

智慧判斷：部門自動分類




模型配置

串接 OpenAI API，可彈性選擇不同版本模型 (如 GPT-4o) 以平衡成本與效能。



Prompt



定義明確規則：根據內容判斷管理、人事、資訊、行銷等部門，並僅回傳分類名稱。



決策路徑

AI 擔任核心大腦，將原本非結構化的郵件內文，轉化為結構化的分類標籤。

第三階段：
結合外部資料庫中的表單內容




結合外部資料庫中的表單內容

AI 結合外部資料庫中的表單內容，將判斷出的部門結果對應至表單中各負責人的信箱地址，實現資料與邏輯的解耦設計。



外部數據串接：Google Sheets 整合

透過與外部 Google Sheets 結合，我們實現了資料與邏輯的解耦設計。當 AI 判定部門後，系統會自動在表單中尋找對應的窗口信箱。



部門名稱	負責人電子郵件信箱	負責工作內容簡述
資訊部	It-dept@company.com	技術支援與系統維護等
人事部	hr-team@company.com	員工招募、保險等
客服部	customer@company.com	第一線客戶諮詢與問題回復

第四階段： 生成郵件草稿並寄送



✈️ 生成郵件草稿並寄送

確定負責人信箱後，系統會自動封裝郵件內容，將原始郵件內容、AI 分析摘要及轉寄聲明進行整合，並依照預設格式編排郵件主旨，生成郵件草稿，並寄送至相關信箱。

自動化轉寄






Python 邏輯封裝 使用 Python 節點將主旨、AI 摘要與部門信箱組合為標準化郵件格式。






自動草稿生成 整合原文與 AI 摘要，並加上轉寄聲明，自動於後台生成轉發郵件。



認證與安全性 全程採用 OAuth2 憑證管理，確保與 Google Workspace 溝通的安全性。





第五階段： 結合LINE BOT進行同步提醒



結合LINE BOT進行同步提醒

在寄出郵件後，系統將郵件主旨與摘要透過 LINE 推播，確保管理者能即時監控並作出反應。

LINE Bot 同步提醒



Messaging API 全面整合

即時通知機制 在郵件成功轉發後，系統同步透過 LINE Bot 推播郵件摘要給管理者。

技術配置 需於 LINE Developers 啟用 Messaging API，並配置 Access Token 與 Generic Auth Type。

核心價值 打破信箱封閉性，讓關鍵決策資訊能夠在移動端被第一時間感知。

100%


實時監控

文字處理部分

報告人：吳奕萱

NLP核心模組總覽

- 在電子郵件自動管理系統中，文字處理模組承擔了核心的決策任務。
- 本研究以Kaggle開源之Customer IT Support - Ticket Dataset作為測試驗證基礎。
- 整體文字處理架構主要分為資料預處理、LLM標記驗證、資料分布調整，以及深度學習分類引擎。



資料預處理流程



提取資料

利用正規表示式從原始工單電子表格中提取「主旨」和「內文」，確保完整捕獲上下文。



語言統一

統一翻譯成繁體中文，以減少口語表達和混合語言環境帶來的干擾。



分類架構萃取

將預先定義的部門標籤和關鍵字被序列化並儲存到知識庫中，後續將用於受限推理。

LLM標記、驗證

- 雙LLM標記引擎：為了確保訓練資料的品質，採用ChatGPT與Gemini作為初始的分類與標記引擎。
- 提示詞工程：將明確的部門定義、少樣本提示與優先判斷規則編碼至模型中；並導入本體論約束機制，動態自知識庫調用專屬標籤清單作為限制條件，大幅降低幻覺與誤判率。
- 多重專家共識標記：僅擷取「資料集原始標籤」、「ChatGPT」和「Gemini」結果完全一致的樣本。

```
SYSTEM_PROMPT = """
你是一個專業的客服工單分類AI。

你的任務是根據 ticket 的「主旨(subject)」與「內容(body)」，
從下列部門選單中選出 **最適合的一個部門**，並挑選對應的 **標籤**。
```

```
=====
【分類選單與定義】
=====
1. [技術支援]：外部客戶遇到 **技術錯誤或系統問題**。
```

```
2. [客戶服務]：客戶帳號或訂單相關問題。
```

```
3. [帳單和付款]：與金錢或帳務相關問題。
```

```
4. [產品支援]：產品 **使用方式或功能問題**（不是壞掉）。
```

```
5. [IT支援]：公司「內部員工」IT問題。
```

```
6. [退貨和換貨]：產品需要退回或更換。
```

```
7. [銷售和售前]：客戶在購買前的問題。
```

```
8. [人力資源]：員工或求職相關問題。
```

```
9. [服務中斷和維護]：系統大規模服務中斷或維護。
```

```
10. [一般詢問]：沒有明確技術問題的普通詢問。
```

```
=====
【判斷規則】
=====
優先判斷：
```

```
1 如果內容提到 付款 / 發票 / 扣款 → [帳單和付款]
```

```
2 如果是 公司內部員工 IT 問題（例如 VPN / access / office）→ [IT支援]
```

```
3 如果是 客戶系統錯誤 / bug / login error → [技術支援]
```

```
4 如果只是 詢問如何使用產品 → [產品支援]
```

```
5 如果是 整個系統不能用 / 網站掛掉 → [服務中斷和維護]
```

```
6 如果是 詢價或購買問題 → [銷售和售前]
```

```
7 如果提到 return / exchange / RMA → [退貨和換貨]
```

```
8 如果與 招聘 / 員工問題 → [人力資源]
```

```
9 如果是 帳號問題或客戶服務流程 → [客戶服務]
```

```
10 如果只是 一般問題且沒有明確技術或帳務問題 → [一般詢問]
```

```

若資訊不足，預設分類：
[一般詢問]
```

```
=====
【各部門可用標籤清單】
=====
{schema_str}
```

```
=====
【強制輸出格式】
=====
你必須以純 JSON 格式輸出，不要包含任何 Markdown 標記（不要用 ```json 包裝）。格式如下：
```

```
{{
  "department": "請填寫一個部門名稱，必須包含中括號，例如 [技術支援]",
  "tags": ["標籤1", "標籤2"]
}}
```


```
注意：標籤必須從上述對應部門的清單中挑選，若無合適標籤請給空陣列 []。
```

```
=====
```



資料分布調整與採樣策略

- 觀察：篩選後的資料集呈現顯著的類別失衡現象。在初步訓練時導致模型極易產生多數類偏見（Majority Class Bias），整體準確率因而受限。
- 修正方式：實施差異化的「階梯式平衡」採樣策略
 - 第一大類「技術支援」與第二大類「帳單與付款」執行下採樣（Down-sampling）。
 - 第三大類「產品支援」與第四大類「服務中斷」執行上採樣（Up-sampling）。
- 目標：使模型能更均勻地學習各部門的語意特徵，避免對單一類別的過度依賴。

多重專家共識標記後之原始樣本數分佈圖



實施階梯式採樣平衡後之訓練集樣本分佈圖



分類表現分析

- 本研究最終選用 Bi-LSTM 模型，其於測試集之整體準確率達到 0.77。
- 模型在「服務中斷和維護」（F1=0.90）與「產品支援」（F1=0.89）類別中展現極高識別能力。
- 「帳單和付款」類別之召回率（Recall）僅為 0.37，顯示該類別與「技術支援」間存在顯著的語意重疊。

Bi-LSTM模型各部門分類成效評估表


部門類別	精準率 (Precision)	召回率(Recall)	F1-Score	測試樣本數
帳單和付款	0.60	0.37	0.46	76
技術支援	0.65	0.88	0.75	142
服務中斷和維護	0.93	0.88	0.90	80
產品支援	0.97	0.82	0.89	106
整體平均	0.79	0.74	0.75	404
加權平均	0.78	0.77	0.76	404

深度學習分類器建構 Bi-LSTM vs. CNN (一)

目的：為提供系統開發者依據不同應用場景進行決策，本研究對比了 Bi-LSTM 與 CNN 兩種架構。

 **Bi-LSTM Model**

利用其遞迴特性捕捉郵件敘述中的長距離因果關係與前後文邏輯。

 **CNN Model**

透過一維卷積層捕捉關鍵詞彙與短語特徵。

總體成效：


- Bi-LSTM 在各項巨集指標上均全面優於CNN，尤其在理解郵件長距離語意依賴上表現優異。
- CNN模型雖整體準確率較低（0.70），但其運算效率極高，每個訓練週期（Epoch）比Bi-LSTM快上近一倍。

模型架構	整體準確率 (Accuracy)	巨集精準率 (Macro Precision)	巨集召回率 (Macro Recall)	巨集 F1-分數 (Macro F1)	訓練速度 (秒 / Epoch)	最佳收斂輪數 (Epochs)
Bi-LSTM	0.77	0.79	0.74	0.75	約 4 ~ 5 秒	50 (穩定收斂)
CNN	0.70	0.72	0.73	0.71	約 1.5 ~ 3 秒	25 (提早停止)

深度學習分類器建構 Bi-LSTM vs. CNN (二)

- 在『服務中斷』與『產品支援』類別，兩者表現相近
→ 此類文本具備明確的特徵詞彙。
- 在語意較為複雜的『技術支援』類別，Bi-LSTM大幅領先
(F1=0.75 vs. 0.57)
→ Bi-LSTM具備較佳的前後文關聯建模能力，能處理長篇且具邏輯性的技術描述。
- 在『帳單和付款』類別，CNN微幅勝過Bi-LSTM
(F1=0.51 vs. 0.46)
→ 印證CNN易受N-grams局部特徵觸發的特性，當郵件中出現『費用、發票、扣款』等高度相關詞彙時，CNN能快速捕捉並分類。

Bi-LSTM與CNN於各部門之 F1-score表現對照圖



錯誤分析與混淆矩陣探討

最終版 Bi-LSTM 模型之混淆矩陣熱力圖

(實際\預測)	帳單和付款	技術支援	服務中斷和維護	產品支援
帳單和付款	28	42	3	3
技術支援	10	125	4	3
服務中斷和維護	2	5	70	3
產品支援	4	10	5	87


- ✓ 基礎成效：對角線數值顯著，模型具備良好分類基礎。
- ⚠ 誤判現象：「技術支援」與「帳單和付款」類別易發生混淆。
- 🔍 根本原因：語意重疊（例如：涉及付費軟體的技術問題），導致文本特徵趨同。
- 🚀 未來優化：針對效能瓶頸，未來可擴充特徵詞庫或最佳化提示詞工程。

影像處理部分


報告人：吳彥瑾

影像處理說明

- 在電子郵件自動管理系統中，影像處理模組負責分析使用者上傳或郵件附件中的圖片內容。
- 進行圖片正規化、尺寸調整，以及文字提示詞整理，讓圖片與文字資料能夠輸入BLIP模型進行多模態分析。
- 最後依據BLIP分析結果與風險判斷規則，將圖片分類為「正常結果」或「異常結果」。



影像處理實驗流程



整理後的簡報脈絡

- 先說明實驗流程與測試案例，再進入四項實驗結果，閱讀順序更自然。
- 案例統一採用 notebook 中的破損手機影像，不再混用原簡報中的 beach demo。
- 每個任務都改成「設定 → 實際輸出 → 解讀」的簡潔結構，便於口頭報告。

主軸
以 BLIP 為基底，
Ollama 補強自然語
言解釋

實驗測試圖片：破損手機螢幕影像

本實驗目的在於驗證 BLIP 與 Ollama 是否能辨識圖片主體、描述破損狀態，並將圖片轉換為可比對的向量或匹配分數。



輸入資訊

- 檔名：8a6.jpg
- 來源：C:\Users\User\Python\mobile01_images
- 視覺主體：手機螢幕出現大面積裂痕

項目	內容
原始尺寸	720 × 960
圖片內容	手機放置於桌面上，螢幕有大面積裂痕與破碎痕跡
核心異常點	手機螢幕破裂
實驗定位	單張案例驗證，不作為完整資料集準確率評估

Image Captioning與Ollama實驗執行結果

- Image Captioning實驗的目的，是觀察模型是否能直接描述出「手機」與「破損」等關鍵資訊。BLIP Captioning 的輸出為「a broken iPhone」，代表模型成功辨識圖片主體為手機，且能指出其破損狀態。不過 BLIP 的描述較短，較接近物件標籤或簡短摘要。
- Ollama 視覺語言模型的輸出較接近人類自然語言說明，能指出手機螢幕嚴重損壞、存在許多裂痕與碎片，並進一步推論可能導致螢幕功能失效。因此，從本實驗得知，BLIP適合擔任影像基礎辨識模組，而Ollama則適合補強使用者可讀的異常原因說明。

模型/方法	輸入設定	實際輸出摘要	結果解讀
BLIP Captioning	384x384	a broken iPhone	能辨識出破損手機，但描述簡短
Ollama gemma3:4b	原圖輸入	手機螢幕嚴重損壞，有許多裂痕和碎片	能產生較完整的中文異常說明

Captioning

BLIP 能辨識「破損手機」，Ollama 則更能說清楚異常原因。

VQA與Ollama實驗執行結果

- VQA 實驗的目的，是將影像描述任務轉換成問答任務，並以「這張照片中有沒有不正常的地方？」作為問題輸入。結果顯示，BLIP VQA 回答為「i don't know」，表示在本案例中，BLIP 對中文異常問題的回答不穩定，無法直接指出螢幕破裂。
- Ollama 視覺語言模型則能明確回答圖片中存在異常，並指出手機螢幕嚴重破碎與裂痕。此結果顯示，若系統需要產生給使用者或管理者閱讀的中文異常說明，僅依賴 BLIP VQA 可能不足，應搭配其他視覺語言模型或規則式後處理。

模型/方法	問題	實際輸出摘要	結果解讀
BLIP VQA	這張照片中有沒有不正常的地方？	i don't know	未能指出異常
Ollama gemma3:4b	這張照片中有沒有不正常的地方？	是的，手機螢幕嚴重破碎，呈現許多裂紋和碎片	能明確指出異常與原因

VQA

在這份案例中，Ollama 對異常問答的表現較穩定。

Feature Extraction 實驗執行結果

- Feature Extraction 實驗不以產生文字描述為目標，而是將圖片轉換為可計算的高維特徵向量。本實驗使用 BLIP Feature Extractor，設定 mode 為 image，輸入尺寸為 224×224 。實驗結果顯示，BLIP 產生的影像特徵維度為 768，輸出向量形狀為 (1,768)。



- 代表由非結構化影像轉換為結構化向量，可供後續相似圖片搜尋、圖片附件分類、異常案例檢索或向量資料庫比對使用。對本系統而言，此功能可用於建立歷史異常附件特徵庫，當新郵件附件進入系統時，即可與過往案例進行相似度比對。

Feature

BLIP 可輸出 768 維向量，方便後續做檢索、相似度比較。

Image-Text Matching實驗執行結果

- Image-Text Matching 實驗使用兩組文字提示進行比較，分別為「正常的商品照」與「異常的商品照」。理論上，若破損手機圖片與「異常的商品照」匹配程度較高，系統即可將圖片標記為異常。

比較項目	輸出結果	說明
正常的商品照	0.0000065831	與正常商品描述的匹配機率較低
異常的商品照	0.0000141245	與異常商品描述的匹配機率較高
最終判定	異常	程式邏輯判定異常描述分數略高於正常描述


- 需要注意的是，本實驗輸出格式原本僅顯示至小數點後四位，因此正常與異常的匹配機率皆顯示為 0.0000，但將輸出精度提高至小數點後十位，即可清楚看出「正常的商品照」匹配機率為 0.0000065831，「異常的商品照」匹配機率為 0.0000141245，由此結果得知，程式邏輯判定異常描述分數略高於正常描述。若從論文嚴謹度來看，後續應將輸出精度提高至小數點後八位或十位，並統一ITM標示，以清楚呈現兩組提示之間的分數差異。

Matching

目前可做相對判定，但建議後續保留更多小數位數，提高分數比較的可讀性。

ITM 的正常與瑕疵檢測詳細流程

- 系統將商品影像與「正常商品」、「瑕疵商品」輸入BLIP，分別產生影像特徵與文字特徵。
- 透過 ITM 計算匹配分數，取得 S_{normal} 與 S_{defect} ，判斷圖片較接近正常描述或瑕疵描述。
- 若 $S_{\text{defect}} > S_{\text{normal}} + \text{閾值}$ ，系統判定為疑似瑕疵；否則判定為正常商品，作為後續自動分類或人工複查依據。



影像分析模組重點整理及說明

- 本模組使用不同影像分析方法，分別檢查圖片描述、「正常」與「異常」問答、特徵向量與文字匹配結果，整理各方法在異常判斷上的表現。

模型/方法	是否指出異常	是否能說明原因	是否適合直接給使用者看	備註
BLIP Captioning	是	部分	普通	輸出a broken iphone，能指出破損手機
BLIP VQA	否	否	不適合	回答i don't know，本案例中文異常問答不穩定
BLIP Feature Extraction	不直接判斷	不適用	不適合直接閱讀	輸出768維向量，適合做檢索與比對
BLIP Image-Text Matching	是	否	普通	可做正常/異常相對判定，但需提高分數精度
Ollama gemma3:4b	是	是	適合	能產生完整中文異常說明

影像處理實驗重點整理

- 本實驗發現 BLIP 適合擔任影像處理基礎模組，尤其在 Captioning、Feature Extraction 與 Image-Text Matching 任務中具有實用價值。然而，BLIP VQA 在中文異常問答情境下表現不穩定，因此若系統需要對使用者輸出自然語言解釋，應搭配 Ollama 視覺語言模型或其他中文表現較佳的多模態模型。

- 1 影像模組補足純文字分類不足：能處理商品照片、維修照片、客訴佐證圖片。
- 2 BLIP 提供四種能力：Captioning、VQA、Feature Extraction、Image-Text Matching。
- 3 實驗案例 8a6.jpg 判定為異常；ITM 分數保留 10 位後，可看出異常提示分數較高。
- 4 最後採決策融合與人工覆核，不誇大成完全自動判斷，較符合論文與簡報嚴謹度。

研究成果總結

研究成果總結

技術、系統、模型與管理價值的整合

面向	成果	意義
技術架構	NLP + LLM + BLIP + 知識庫 + n8n	多模態郵件管理流程
系統實作	郵件擷取、查表、轉寄、LINE 通知	具備企業導入可行性
文字分類	Bi-LSTM Accuracy 0.77 / Macro F1 0.75	部門分類穩定性提升
影像分析	BLIP + ITM + 規則式決策	補強圖片附件判斷
管理價值	效率提升 80%+、誤判率降低 70%	降低人力成本並支援 ESG

核心價值：將生成式 AI 從「產生文字」推進到「驅動行政流程」，形成可追蹤、可擴充、可治理的智慧工作流。

研究限制與補強方向

讓系統從概念驗證走向正式部署

- 資料限制：客服工單資料與企業真實行政信箱仍有差異，需要在地化語料。
- 分類限制：單一標籤難處理跨部門案件，應擴充多標籤與信心門檻。
- 影像限制：目前以單案示範為主，需建立大規模正常/異常圖片集。
- 安全限制：雲端模型整合便利，但高敏感環境需評估地端 LLM、權限控管與稽核。

結論：iMercury 可由郵件分派工具擴展為行政協作平台

未來可導入 RAG、OCR、多標籤分類、地端 LLM 與治理儀表板

- 短期：優化部門 taxonomy、補強提示詞與誤判案例庫。
- 中期：加入 OCR、附件類型辨識與多模態檢索。
- 長期：整合地端 LLM、權限管理、日誌稽核與 ESG 管理指標。

總結：iMercury 的研究價值在於把 AI agent、知識工程與流程治理結合，使企業行政流程由「人工分派」走向「智慧協作」。

參考文獻

參考文獻 REFERENCES

- [1] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A. C., Lo, W.-Y., Dollár, P., & Girshick, R. (2023). Segment Anything. arXiv preprint arXiv:2304.02643. <https://arxiv.org/abs/2304.02643>
- [2] Li, J., Li, D., Xiong, C., & Hoi, S. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. arXiv preprint arXiv:2201.12086. <https://arxiv.org/abs/2201.12086>
- [3] Li, J., Li, D., Savarese, S., & Hoi, S. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. arXiv preprint arXiv:2301.12597. <https://arxiv.org/abs/2301.12597>
- [4] n8n. (2026). n8n documentation. Retrieved May 18, 2026, from <https://docs.n8n.io/>
- [5] n8n. AI Workflow Automation Platform. Retrieved May 18, 2026, from <https://n8n.io/>
- [6] Bueck, T. (n.d.). Customer IT support - Ticket dataset. Kaggle. Retrieved May 18, 2026, from <https://www.kaggle.com/datasets/tobiasbueck/multilingual-customer-support-tickets>
- [7] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language models are few-shot learners. In Advances in Neural Information Processing Systems, 33, 1877–1901. <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- [8] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In Proceedings of NAACL-HLT 2019 (pp. 4171–4186). Association for Computational Linguistics. <https://aclanthology.org/N19-1423/>
- [9] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems, 30. <https://papers.neurips.cc/paper/7181-attention-is-all-you-need>
- [10] Google. (2026). Google Sheets API documentation. Google for Developers. Retrieved April 27, 2026, from <https://developers.google.com/workspace/sheets/api/guides/concepts>
- [11] LINE Corporation. (2026). Messaging API documentation. LINE Developers. Retrieved April 27, 2026, from <https://developers.line.biz/en/docs/messaging-api/>
- [12] OpenAI. (2026). OpenAI API platform documentation. Retrieved April 27, 2026, from <https://platform.openai.com/docs>
- [13] Ruan, Q., Kuznetsov, I., & Gurevych, I. Are Large Language Models Good Classifiers? A Study on Edit Intent Classification in Scientific Document Revisions. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, 15049–15067. Association for Computational Linguistics. 2024. <https://doi.org/10.18653/v1/2024.emnlp-main.839>

參考文獻 REFERENCES

- [14] Mirza, P., Sudhi, V., Sahoo, S. R., & Bhat, S. R. ILLUMINER: Instruction-tuned Large Language Models as Few-shot Intent Classifier and Slot Filler. In Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), 8639–8651. 2024. <https://aclanthology.org/2024.lrec-main.758/>
- [15] Vukovic, R., Arps, D., van Niekerk, C., Ruppik, B. M., Lin, H.-C., Heck, M., & Gašić, M. Dialogue Ontology Relation Extraction via Constrained Chain-of-Thought Decoding. In Proceedings of the 25th Annual Meeting of the Special Interest Group on Discourse and Dialogue (SIGDIAL 2024). 2024. <https://doi.org/10.48550/arXiv.2408.02361>
- [16] Park, K., Wang, J., Berg-Kirkpatrick, T., Polikarpova, N., & D’Antoni, L. Grammar-Aligned Decoding. In Advances in Neural Information Processing Systems, 37. 2024. <https://doi.org/10.48550/arXiv.2405.21047>
- [17] Ravi, N., Gabeur, V., Hu, Y.-T., Hu, R., Ryali, C., Ma, T., Khedr, H., Rädle, R., Rolland, C., Gustafson, L., Mintun, E., Pan, J., Alwala, K. V., Carion, N., Wu, C.-Y., Girshick, R., Dollár, P., & Feichtenhofer, C. SAM 2: Segment Anything in Images and Videos. arXiv preprint arXiv:2408.00714. 2024. <https://doi.org/10.48550/arXiv.2408.00714>
- [18] Özdemir, Ö., & Akagündüz, E. Enhancing Visual Question Answering through Question-Driven Image Captions as Prompts. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 1562–1571. 2024. https://openaccess.thecvf.com/content/CVPR2024W/PV/html/Ozdemir_Enhancing_Visual_Question_Answering_through_Question-Driven_Image_Captions_as_Prompts_CVPRW_2024_paper.html
- [19] Su, H., Luo, W., Han, W., Liu, Y., Zhang, Y., Zhao, C., Zhang, J., & Mehdad, Y. LLM-Friendly Knowledge Representation for Customer Support. In Proceedings of the 31st International Conference on Computational Linguistics: Industry Track, 496–504. Association for Computational Linguistics. 2025. <https://aclanthology.org/2025.coling-industry.42/>
- [20] Liu, F., He, X., Zhang, T., Chen, J., Li, Y., Yi, L., Zhang, H., Wu, G., & Shi, R. TickIt: Leveraging Large Language Models for Automated Ticket Escalation. In Proceedings of the 33rd ACM International Conference on the Foundations of Software Engineering. 2025. <https://doi.org/10.1145/3696630.3728558>
- [21] Alekseev, I., Solomatin, R., Rustamova, D., & Kuznetsov, D. AutoIntent: AutoML for Text Classification. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 707–716. Association for Computational Linguistics. 2025. <https://aclanthology.org/2025.emnlp-demos.53/>

感謝您的聆聽